fwdays academy

Модуль 7

Evaluation & guardrails

Design

Tests can be added directly to your application. These are typically simple assertions fast enough to be executed at runtime. Using an orchestrator system can help execute these tests and feed failures back to the LLM. The goal is to catch and self-correct errors *within your app* itself before they affect users.

Pre-Production

Tests can be run before deploying your application into production. These typically cover key scenarios your application must pass, based on data you've collected. The goal is to catch and fix any regressions before the app is released to real users.

Post-Production

Tests can be run on your application in production. These help monitor and catch errors or undesirable behavior affecting real users. The goal is to identify issues and feed them back into the design or pre-production phases, creating a continuous cycle of "design, test, deploy, monitor, fix, and redesign".

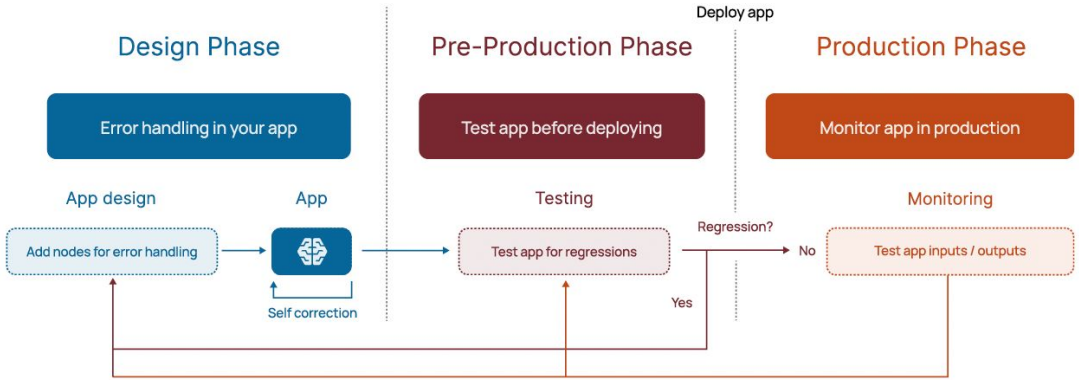

Створення системи для виявлення помилок перед розгортанням: LangSmith

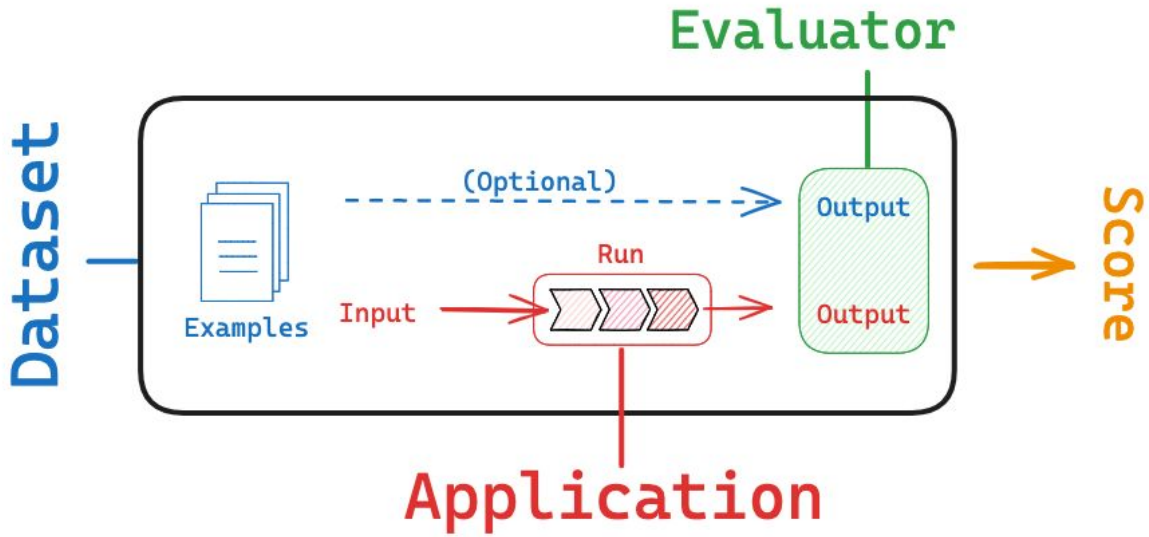

https://docs.smith.langchain.com/concepts/evaluation
https://docs.google.com/presentation/d/1QWkXi4DYjfw94eHcy9RMLqpQdJtS2C_kx_u7wAUvlZE/edit?slide=id.g273e7f400bc_0_102#slide=id.g273e7f400bc_0_102

Agent evaluation - тестування

Датасет - це колекція тестових питань і завдань для перевірки якості вашого AI агента.

Датасет складається з:

- 📝 Питання/завдання (що даємо агенту)
- ✅ Еталонні відповіді (що очікуємо отримати)
- 🏷️ Мітки і категорії (тип питання, складність)
- 📊 Метрики оцінювання (як вимірюємо успіх)

https://arize.com/ai-agents/agent-evaluation/

Ключові метрики

Метрика	Що вимірює	Приклад застосування
Точність (Accuracy)	Наскільки відповіді/дії агента правильні відносно еталону чи очікування	Відсоток правильних відповідей
Latency (Затримка)	Час відповіді агента (реактивність)	Середній час відповіді чат-бота в секундах
Hallucination Rate	Частка відповідей з вигаданою або недостовірною інформацією	% фактологічних помилок у відповіді
Coverage / Recall	Повнота – наскільки агент охоплює всю релевантну інформацію	Частка знайдених потрібних документів у RAG
Task Success Rate	Відсоток завдань, які агент виконує успішно	Скільки діалогів завершено із задовільним результатом
Reliability & Trust	Стабільність і передбачуваність поведінки агента, довіра користувачів	Консистентність відповідей на однакові запити
Cost Efficiency	Витрати ресурсів відносно користі	Вартість API-викликів чи кількість токенів на відповідь
User Satisfaction	Задоволеність користувачів взаємодією	CSAT/NPS опитування, рейтинг відповідей, повторні звернення

Фреймворки

Arize Phoenix

Open-source, глибокий трейсинг агентів, LLM-as-a-judge метрики, CI/CD інтеграції.

LangSmith

Інтеграція з LangChain, збір трейсів, людська та LLM-оцінка, моніторинг у продакшн.

TruLens

Вбудовані метрики (relevance, groundedness, toxicity), кастомні feedback functions.

RAGAS

Спеціалізація на retrieval-augmented generation (precision, recall, faithfulness).

Promptfoo

Просте тестування промптів, перевірки regex/JSON, легка інтеграція в CI.

LLM Eval

Бенчмарки, класичні метрики (F1, BLEU, ROUGE), кастомні eval-и.

EvalGen

Генерує метрики за допомогою LLM, узгоджує з людськими оцінками.

Метрики у фреймворках

Фреймворк	Accuracy	Latency	Hallucinations	Coverage / Recall	Task Success	Reliability	Cost	User Satisfaction
Arize Phoenix	✓	✓	✓	✓	✓	✓	✓	✓
LangSmith	✓	✓	✓	✓	✓	✓	✓	✓
TruLens	✓	✓	✓	✓	✗	✓	✓	✗
RAGAS	✓	✗	✓	✓	✗	✗	✗	✗
Promptfoo	✓	✓	✗	✗	✗	✗	✓	✗
LLM Eval	✓	✗	✗	✓	✗	✗	✗	✗
EvalGen	✓	✗	✓	✗	✓	✓	✗	✓

fwdays academy

Модуль 7.1

Guardrails

Guardrails

Guardrails (захисні обмеження) – це програмні «рейки безпеки», що регулюють взаємодію користувача з AI-моделлю та тримають її поведінку в визначених межах політик.

По суті, guardrails виступають проміжним шаром між користувачем і ядром моделі, який **перевіряє вводи та виводи моделі,** щоб запобігти небажаним результатам.

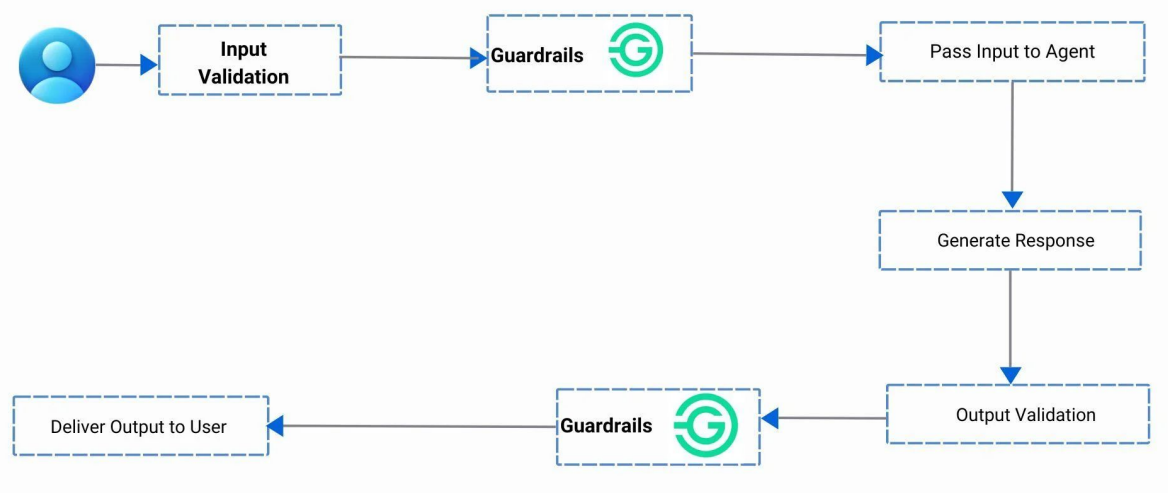

Категорія ризику	Приклади	Як стримують guardrails
Токсичний / неприйнятний контент	Ненависть, образи, сексуальний контент, насильство	Класифікатори токсичності, фільтри контенту (Moderation API, NeMo Guardrails, Perspective API); блокування або редагування відповіді
Витік даних (PII, секрети)	Телефон, email, адреси, фінансові дані, корпоративна інформація	Детектори PII (Presidio, DLP API, LLM Guard); маскування, блокування чи вилучення з промптів/відповідей
Шкідливі інструкції	Рецепти вибухівки, інструкції хакерства, поради самошкоди	Вбудовані безпечні моделі (RLHF, Constitutional AI); runtime-фільтри за темами (denied topics в Bedrock); відмова у відповіді
Prompt injection / jailbreak	“Ігноруй попередні правила”, приховані інструкції у файлах чи текстах	Спеціалізовані класифікатори (PromptGuard, LlamaFirewall), аналіз промптів; відхилення небезпечних запитів
Неправильні або небезпечні дії агентів	Виклик небезпечних API, виконання шкідливого коду, фінансові операції без дозволу	Обмеження списку інструментів, контроль параметрів викликів; CodeShield (аналіз коду); людське підтвердження для критичних дій
Галюцинації / дезінформація	Вигадані факти, фальшиві цитати, помилкові поради	Фактові перевірки в RAG; вимога цитувати джерела; моделі-монітори (Fiddler Guardrails, WhyLabs) з відміткою галюцинацій
Експлуатація вразливостей	Спроби витягти тренувальні дані, атаки на контекст	Ліміти на токени, відстеження аномалій; додаткові guard-моделі для перевірки контексту

Інструмент	Опис / Сильні сторони
Guardrails AI	Валідація вводу/виводу LLM за схемами (RAIL), готові шаблони, інтеграція з LangChain.
NVIDIA NeMo Guardrails	Конфігуровані input/output/topical рейки для діалогових агентів; інтеграція з ActiveFence.
Microsoft Guidance	Шаблони для структурованого виводу LLM; контроль формату (JSON, SQL тощо).
LlamaFirewall (Meta)	Prompt injection захист (PromptGuard 2), перевірка reasoning (AlignmentCheck), аналіз коду (CodeShield).
LLM Guard	Простий Python-SDK для PII, токсичності, prompt injection; легка інтеграція.
Fiddler Guardrails / TruLens	Оцінка галюцинацій, модерація, інтеграція з NeMo або LangChain.

Практики та інструменти моніторингу

Категорія	Інструменти / Практики
Логування	ELK, Prometheus+Grafana, Langfuse/LangSmith
Моніторинг якості	Phoenix (Arize), WhyLabs/WhyLogs, Fiddler AI
Red Teaming	Adversarial prompting, GAR frameworks, Fuzzing
Політики	OPA, CalypsoAI Moderator
CI/CD	Unit-тести guardrails, Canary deploy
Вдосконалення	Feedback loops, Active learning

Модуль 7 .2

fwdays academy

Тестування та масштабування

Agent Development Lifecycle (ADLC)

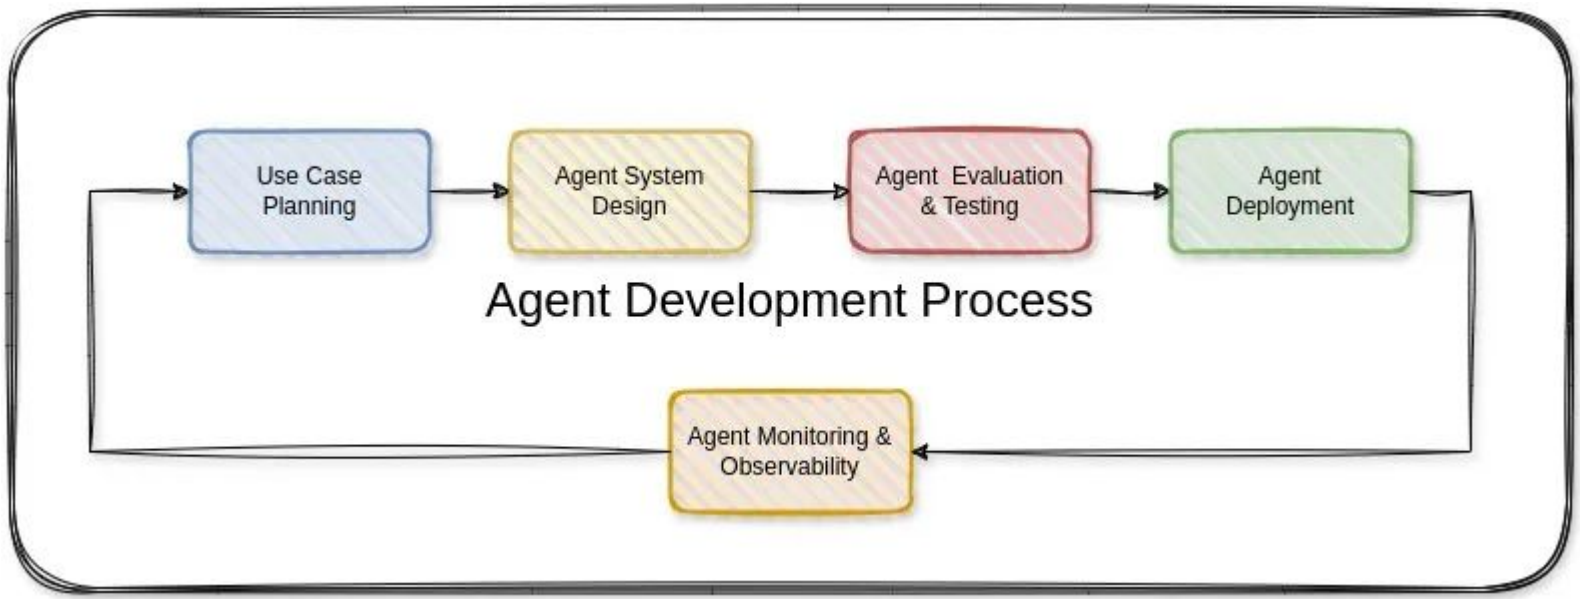

https://sanjmo.medium.com/demystifying-ai-agents-frequently-asked-questions-faq-a9748b4f55e6

A snapshot of the AI Agents Ecosystem

February 2025

Agent Frameworks

LangGraph
KaibanJS
DSPy
Letta
crewai
phidata
Semantic Kernel
autogpt
LlamaIndex
AG

Memory

MemGPT
LangMem
zep
mem0

Observability

AgentOps.ai
LangSmith
arize
Braintrust
Langfuse
weave

Tool Library

tavily
exa
zapier
Firecrawl
composio
make
jina

Agent Hosting & Serving

Amazon Bedrock Agents
Letta
Assistants API
LiveKit
LangGraph
Agents API

Observability

LLM Monitoring & Observability

arize

fiddler

AgentOps.ai

Grafana

OpenTelemetry

Prompt Management & Engineering

Langfuse

PromptHub

PromptLayer

LLM Evaluation

deepchecks.

PHOENIX

Weights & Biases

mlflow
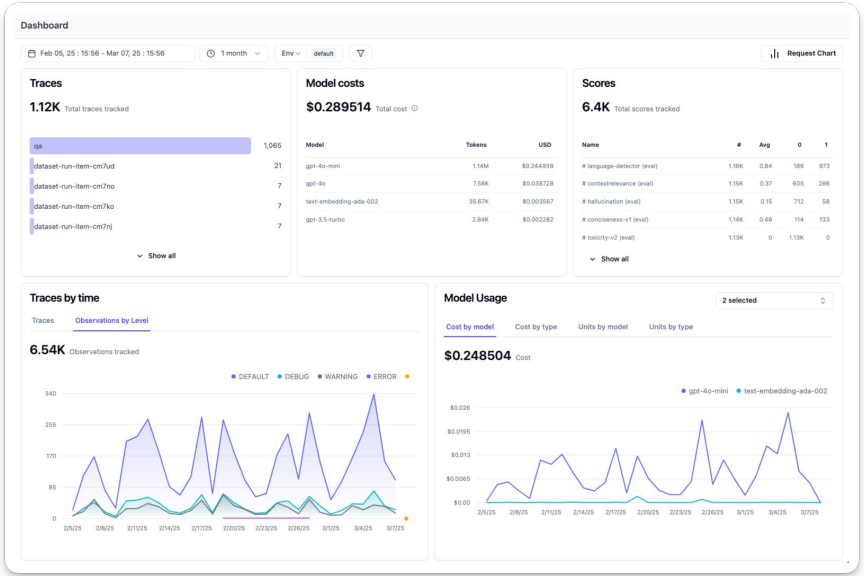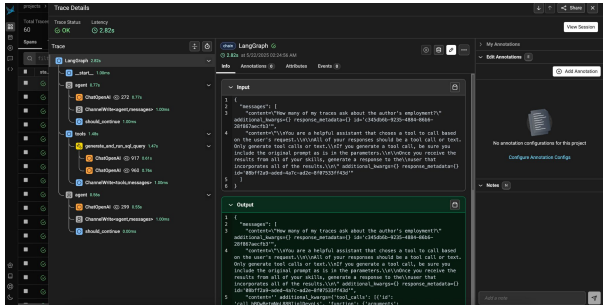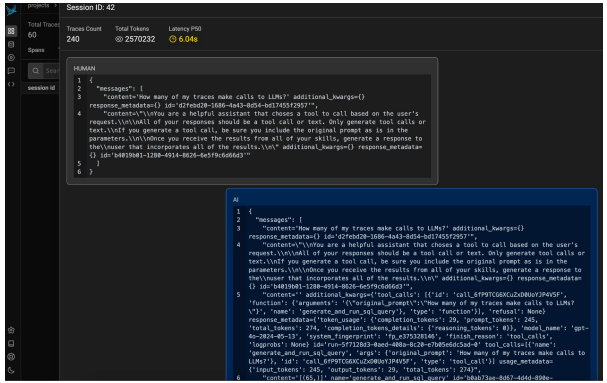
Observability/спостережуваність